

SISTEMA OCR INTELIGENTE CON RESÚMENES AUTOMÁTICOS

Automatización, Privacidad e Inteligencia Artificial Local para el
Procesamiento Documental

| ¿Qué es el Sistema?

Es una solución integral automatizada que detecta, extrae y analiza contenido de documentos PDF mediante OCR y genera resúmenes inteligentes.

Funcionalidad Principal:

- **Detección Inteligente:** Identifica texto embebido vs. imágenes.
- **OCR Optimizado:** Se aplica solo cuando es necesario, preservando originales.
- **IA Local:** Genera resúmenes contextuales sin enviar datos a la nube.



Finalidad del Proyecto

Convertir archivos estáticos y no buscables en documentos completamente digitalizados con capacidad de análisis.



Archivos Históricos

Digitalización de documentos antiguos escaneados preservando su estructura.



Documentos Legales

Procesamiento masivo de expedientes y reportes extensos.



Administración

Conversión y extracción de datos en facturas y documentos administrativos.

Objetivos del Sistema

🎯 Objetivos Principales

- **Automatización:** Eliminar procesamiento manual.
- **Precisión:** Tesseract + OCRmyPDF en español.
- **Eficiencia:** OCR selectivo inteligente.
- **Inteligencia:** IA local para resúmenes.

★ Objetivos Secundarios

- Reducción de costos operativos.
- Privacidad total (Sin dependencias Cloud).
- Preservación de calidad original.
- Facilitar búsqueda en grandes volúmenes.

Stack Tecnológico

CORE & PDF

Python 3.8+, PyMuPDF, OCRmyPDF

MOTOR OCR


Tesseract OCR 5.x (Español nativo)

INTELIGENCIA ARTIFICIAL

Ollama Server + Mistral 7B (Local LLM)


UX & TOOLS

Colorama, Tqdm, Native Logging



Arquitectura Modular

- 📁 **Capa de Presentación:**
CLI Interface (main.py)
- ⚙️ **Capa de Servicios:**
Summary Service, AI Service
- 📁 **Capa de Negocio:**
PDF Detector, OCR Processor, File Manager
- 🗄️ **Servicios Externos:**
Tesseract OCR Engine, Ollama Server



Fase 1: Flujo OCR Inteligente



Fase 2: Resúmenes con IA (Ollama)



Ventajas Competitivas



- **Privacidad Total:** IA ejecutada 100% localmente. Sin fugas de datos.
- **Detección Inteligente:** Ahorra recursos evitando procesar PDFs que ya tienen texto.
- **Resúmenes Adaptativos:** Ajusta la longitud según el tamaño del documento.
- **Open Source:** Sin costos de licencias, basado en tecnologías libres.

Estado de Funcionalidades

✓ Fase 1: Completada

OCR Automático

- Detección Contenido (Texto vs Imagen)
- OCR Alta Precisión (Español)
- Corrección de inclinación (Deskew)
- Logs detallados y validaciones
- CLI Colorida

🔄 Fase 2: En Desarrollo

Resúmenes con IA

- Limpieza avanzada de texto
- Chunking estratégico con overlap
- Integración Ollama / Mistral 7B
- Salida JSON con metadata
- Vista previa en consola

Roadmap Futuro

Fase 3: Análisis Avanzado

Extracción de entidades (NER), detección de idioma automática.

Fase 4: Procesamiento en Lote

Colas de trabajo, paralelismo y dashboard de monitoreo.

Fase 5 & 6: API & Web

API REST (FastAPI) e Interface Web (React/Vue) con Drag & Drop.



Métricas de Rendimiento

>95%

Precisión OCR

~3s

Por Página (OCR)

~30s

Por Chunk (IA)

Requisitos: 4GB RAM Mínimo (8GB Recomendado) | Espacio: 10GB

TRANSFORMANDO DOCUMENTOS EN CONOCIMIENTO

Un sistema completo que combina OCR tradicional con IA moderna para
una digitalización eficiente y privada.

Gracias por su atención

Image Sources



https://aijourn.com/wp-content/uploads/2025/07/shutterstock_2489214235-Large-780x470.jpeg

Source: aijourn.com



https://miro.medium.com/1*tjHTmF_ISUY6_pykU6_VpQ.gif

Source: [betterprogramming.pub](https://miro.medium.com/1*tjHTmF_ISUY6_pykU6_VpQ.gif)



<https://blog.cleancoder.com/uncle-bob/images/2012-08-13-the-clean-architecture/CleanArchitecture.jpg>

Source: blog.cleancoder.com



https://static.vecteezy.com/system/resources/previews/006/878/538/non_2x/guard-shield-cyber-security-concept-with-glowing-low-poly-shield-on-dark-blue-background-wireframe-low-poly-design-abstract-futuristic-illustration-vector.jpg

Source: www.vecteezy.com



<https://en.pimg.jp/093/393/101/1/93393101.jpg>

Source: www.pixtastock.com



https://static.vecteezy.com/system/resources/previews/000/518/473/non_2x/abstract-background-for-cyber-technology-futuristic-concept-on-the-dark-blue-background-vector-illustration.jpg

Source: www.vecteezy.com