

ARQUITECTURA DEL SISTEMA

OCR INTELIGENTE Y DIGITALIZACIÓN

Automatización, Detección Inteligente y Procesamiento de
Documentos PDF

000000011011010

100

El núcleo del sistema es la capacidad de transformar archivos estáticos en datos estructurados sin intervención manual.

Funciones Clave:

- **Detector PDF:** Algoritmo que decide automáticamente si un archivo necesita OCR o solo extracción.
- **Optimización:** Reduce el tamaño del archivo final y corrige la inclinación (Deskew).
- **Preservación:** Mantiene la apariencia visual exacta del documento original.



| Objetivos del Módulo OCR

</> Objetivos Técnicos

- **Precisión >95%:** Configuración optimizada de Tesseract para español.
- **Eficiencia de Recursos:** Evitar re-procesar documentos que ya son digitales.
- **Arquitectura Modular:** Componentes desacoplados para fácil mantenimiento.

Impacto Operativo

- Eliminación total de la digitación manual de documentos.
- Conversión masiva de archivos históricos (imágenes) a PDFs buscables.
- Base sólida y limpia para el posterior análisis con Inteligencia Artificial.

Stack Tecnológico

OCR

MOTOR PRINCIPAL

Tesseract OCR 5.x

El estándar open-source más robusto para reconocimiento de texto.

ORQUESTADOR PDF

OCRmyPDF + PyMuPDF

Gestión de capas, metadatos y optimización de imágenes.

LENGUAJE CORE

```
import matplotlib.pyplot as plt

def generate Mandelbrot fractal(
    c, max_iter):

    for n in range(max_iter):
        if abs(z) > 2:
            return n
        z = z*z + c
    return max_iter

# dimensions
width = 800, height = 800

# key area parameters
c_re_max = -2.0, 1.0
c_im_max = -1.5, 1.5
```


Flujo de Trabajo: Fase 1



| Estado Actual y Métricas

✓ FASE 1: COMPLETADA

>95%

Precisión (Español)

~3s

Velocidad por Página

100%

Local (Offline)



Implementado con logs detallados, manejo de errores y validación de archivos.

BASE SÓLIDA IMPLEMENTADA

El módulo de OCR proporciona la fundación crítica para la digitalización, transformando documentos "muertos" en datos listos para ser consumidos por la Inteligencia Artificial.

— Fin de la sección OCR —

| Image Sources



https://miro.medium.com/v2/resize:fit:1400/1*qbKfNDVFXB6DjrmkkTOnyA.png

Source: medium.com



https://img.freepik.com/premium-photo/python-code-dark-theme-ide-monitor-screen_480058-394.jpg

Source: www.freepik.com



https://img.freepik.com/premium-photo/abstract-digital-data-streams-dark-blue-background-conveying-concept-big-data-cloud-technology-3d-rendering_670147-105777.jpg

Source: www.freepik.com